Pipeline ETL bancario con zona de cuarentena

Reporte técnico de integración y entrega

Equipo: **Avilix · Maki · Leo**
Fuentes: cajeros ATM y transferencias digitales.
Corte de preparación: 26 de octubre de 2026.

Responsable	Especialidad
Maki	Perfilado, faltantes, duplicados y outliers
Avilix	Integración, transformación, orquestación e interfaces
Leo	Pydantic, cuarentena, persistencia y resiliencia

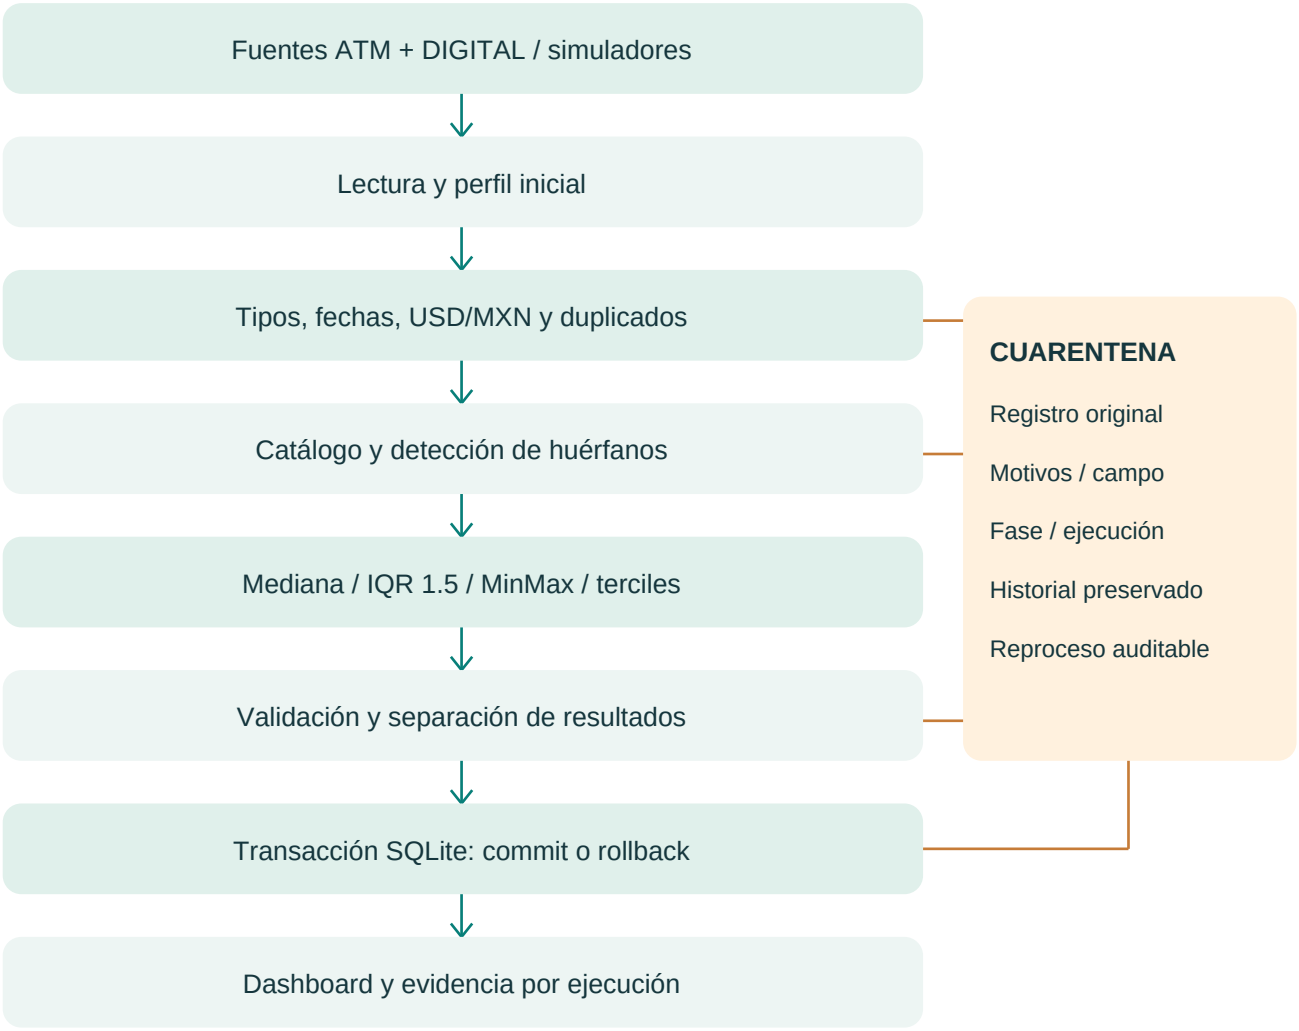
Resultado reproducible

Fuente	Leídas	Limpias	Cuarentena	Omitidas
ATM	620	568	32	20
DIGITAL	600	504	96	0
TOTAL	1220	1072	128	20

La conciliación es 1,220 = 1,072 + 128 + 20. Los rechazos se conservan; las omisiones corresponden a duplicados exactos. La base entregable contiene solo las fuentes originales, sin las operaciones manuales de prueba.

Repositorio: https://github.com/Av1l1X/Pipeline_Banco
Base: entrega/pipeline_banco.sqlite
Evidencia detallada: entrega/resultados.json

Un solo recorrido de datos



La validación temprana impide que importes o claves corruptas contaminen los parámetros estadísticos. Los formularios utilizan parámetros de un lote previo de su fuente. La validación final comprueba las variables analíticas antes de persistir.

El catálogo CSV se valida como snapshot completo. Se conserva la versión aplicada a cada registro; los huérfanos van a cuarentena. Las filas omitidas también tienen bitácora y forman parte de la conciliación.

El diagrama editable está en docs/DIAGRAMA.md. El encabezado de la guía dice “6 fases”, pero enumera siete; esta implementación cubre también la carga transaccional de la fase 7.

Medir antes de transformar

Fuente / campo	Nulos	Vacíos	% ausencia	Tipos observados
ATM / id_cajero	44	0	7.1	str
ATM / monto_mxn	27	0	4.35	str
DIGITAL / notification_email	8	8	2.66	str

Se cuentan nulos y cadenas vacías por separado. El ATM contiene 20 duplicados exactos. El perfil completo conserva tipos observados y categorías por columna; no reemplaza las fuentes.

Hipótesis MCAR/MAR y límites

Las ausencias de monto/comisión se tratan bajo una hipótesis MAR operativa: el grupo de operación, estado o cajero puede aportar información al valor faltante. Una omisión aislada de concepto o identificador de cajero es compatible con MCAR, pero el perfil descriptivo no demuestra independencia. No se presenta ninguna de estas hipótesis como causalidad comprobada.

Se imputa mediana por grupo con al menos cinco valores observados válidos. Es menos sensible a colas y extremos que la media. Se guardan ambas medidas y el tamaño del grupo para auditar la elección. Si no hay base suficiente, se rechaza; no se inventa un importe.

Las categorías faltantes se sustituyen por DESCONOCIDO o SIN_CONCEPTO. El correo es opcional, pero si está presente debe ser válido. Una consulta de saldo tiene importe cero; ese cero no significa un saldo bancario real.

Conservar el origen, explicar el cambio

Regla	Aplicación
Dinero	Decimal; USD × 19.50; HALF_UP a dos decimales. Se conserva importe y moneda originales.
Fechas	Parseo por fuente, fecha ISO YYYY-MM-DD y fecha/hora UTC-06:00. Fechas imposibles o ambiguas se rechazan.
IQR	Q1 y Q3 con interpolación lineal; límites Q1 – 1.5 IQR y Q3 + 1.5 IQR, inferior no negativo. No se ajusta con importes imputados.
Capping	Solo cambia monto_analitico_mxn. monto_mxn permanece como importe de operación. Con menos de cinco observaciones o IQR cero no se recorta.
MinMax	(x – mínimo)/(máximo – mínimo), por fuente y operación. Grupo constante: cero. Manual fuera de rango se acota y marca; referencia constante incompatible se rechaza.
Segmentos	Terciles del grupo: BAJO hasta primer corte, MEDIO hasta segundo, ALTO después. Consulta de saldo: BAJO.

Efecto en los datos aceptados

119 registros se marcaron como outliers; 27 registros registraron cambios en la etapa de imputación. Esta última cifra no cuenta las normalizaciones deterministas realizadas antes por los validadores.

Segmento	Registros
BAJO	452
MEDIO	338
ALTO	282

La comparación antes/después usa poblaciones distintas: antes son las filas crudas; después son las aceptadas. Una reducción de nulos puede deberse tanto a imputación como a separación en cuarentena, por lo que no se atribuye toda la mejora a la limpieza.

Aceptar, aislar y poder auditar

Motivo registrado	Ocurrencias
CLABE_INVALIDA	46
CORREO_INVALIDO	30
CUENTA_NO_REGISTRADA	56

Hay 128 filas en cuarentena y 132 ocurrencias de motivos. Las categorías se superponen: una fila puede contener varios errores. Un registro rechazado en validación temprana no alcanza necesariamente el cruce de catálogo; los conteos son errores detectados en el recorrido, no un inventario exhaustivo de todos los defectos latentes.

Integridad y transacciones

SQLite contiene transacciones_limpias y cuarentena_errores, además de ejecuciones, catálogo versionado, evidencia y bitácoras. Los importes Decimal se guardan como texto exacto dentro del payload JSON. La carga de filas, cuarentena y evidencias se confirma de forma atómica. Ante fallo se revierte y queda una ejecución FALLIDA.

La entrega pasó PRAGMA integrity_check y foreign_key_check. La unicidad fuente/ID y la huella de origen impiden recargas duplicadas. Una carga idéntica devuelve el resumen previo; un ID con contenido distinto se desvía a cuarentena.

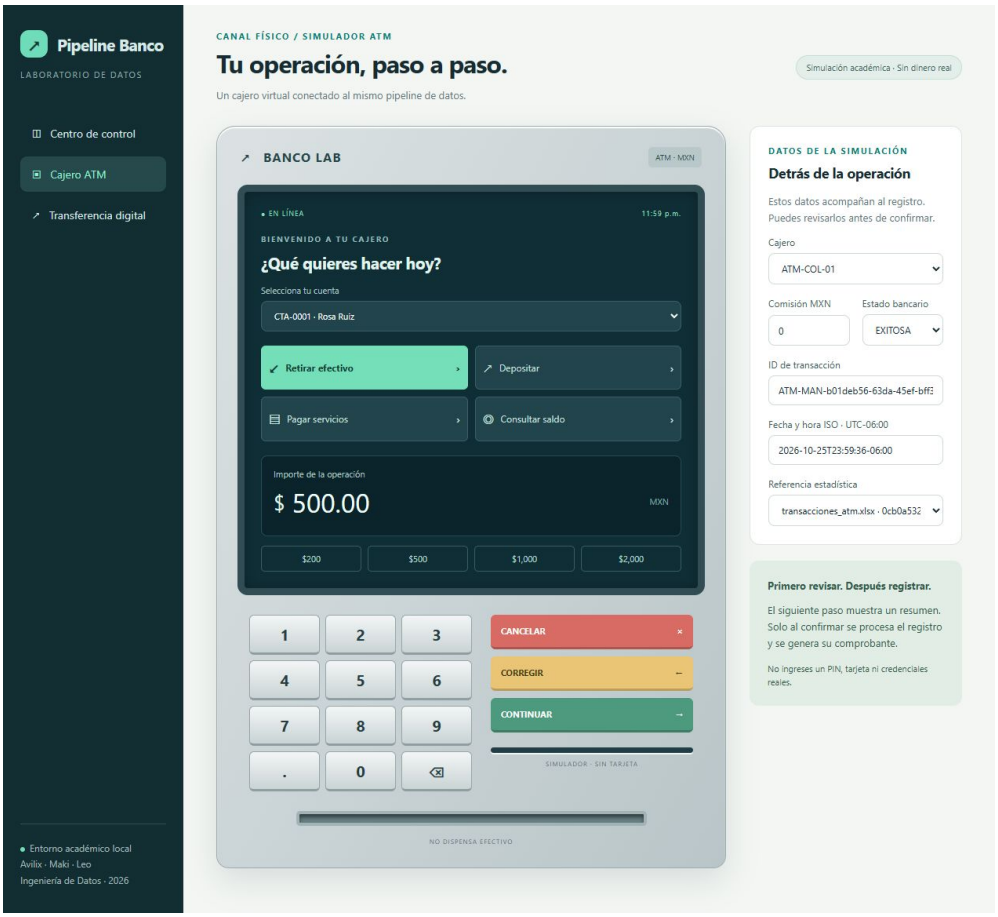
Pruebas automatizadas y de interfaz

50 pruebas aprobadas: validación, fechas ambiguas, números no finitos, CLABE/correo, huérfanos, duplicación, referencias manuales, rollback, catálogos, filtros y archivos ilegibles. Se conserva la salida en entrega/pruebas.txt. Hay una advertencia de deprecación del adaptador httpx de TestClient; no es un fallo de prueba.

Verificación manual del navegador: teclado ATM, corrección, revisión, confirmación e inserción; transferencia con CLABE inválida y comprobante EN_CUARENTENA con motivo visible. Los datos de estas pruebas están en la base de trabajo, no en la base entregable.

Interfaz para observar el pipeline

El dashboard muestra limpias, cuarentena, duplicados, cargas, filtros, gráficas y detalles de trazabilidad. También admite archivos nuevos y reprocesamientos. Las interfaces ATM y digital son distintas, pero ambas escriben mediante la misma API y reglas.



Captura de prueba local. Los identificadores y conteos de la interfaz pueden incluir demostraciones; el resumen oficial proviene de la base entregable.

Inicio: instalar requirements.txt con Python 3.12 y ejecutar iniciar.cmd. Abrir http://127.0.0.1:8765. La terminal mantiene el servidor; Ctrl+C lo detiene. Los pasos completos y comandos de reproducción están en README.md.

El servicio es local y usa un solo proceso. No implementa autenticación ni una operación bancaria real. Las consultas cargan filas en memoria y están orientadas al tamaño académico de los datos.

Evidencias para revisar y reproducir

Requisito de la guía	Evidencia
Reglas y mockup	REGLAS_DE_NEGOCIO.md y docs/DIAGRAMA.md
Calidad antes/después	src/calidad.py, src/limpieza.py; perfiles en resultados.json
Integración y transformación	src/integracion.py, src/transformacion.py, src/pipeline.py
Pydantic y cuarentena	src/validation.py; tabla cuarentena_errores
Persistencia y resiliencia	src/persistence.py; tests/; entrega/pruebas.txt
Repositorio, BD y reporte	GitHub; pipeline_banco.sqlite; este PDF
Defensa individual	docs/DEFENSA.md; explicación en vivo de los tres integrantes

Fuentes y reproducibilidad

1. GUIA_LINEAMIENTOS_PROYECTO_ALUMNOS.pdf, pp. 1–3, documento proporcionado por el docente: objetivo, fases, entregables y rúbrica.
2. datasets/catalogo_cuentas.csv, datasets/transacciones_atm.xlsx y datasets/transferencias_digitales.json: fuentes originales recibidas.
3. entrega/resultados.json y pipeline_banco.sqlite: mediciones producidas por este código. SHA256.json identifica los archivos usados.

El CSV ATM de la raíz se conserva del aporte previo; los resultados aquí usan el XLSX original recibido. No se mezclan ambas versiones de la misma fuente.

Para reproducir: python -m scripts.preparar_entrega --salida outputs/reproduccion. El comando se niega a sobreescribir una base existente. Después ejecutar scripts/generar_reporte.py con --carpeta outputs/reproduccion.

Las firmas reales de Avilix, Maki y Leo en las reglas y la defensa oral son acciones personales pendientes de los integrantes. Este reporte no simula firmas ni acredita una exposición que no se ha realizado.